

İsim ve Diğer Öbeklerin Saptanması (Chunking)

Ders Adı: Doğal Dil İşlemlerine Giriş

Programlama Dili: Python


Github: https://github.com/Rima2002/NLP_chunking

Adı Soyadı: Rima Farah Eleuch

Öğrenci Numarası: 21360859216

1. Giriş

Bu projede Türkçe cümlelerdeki isim öbekleri, eylem öbekleri, zarf öbekleri ve cümlecik yapılarının otomatik olarak etiketlenmesi amaçlanmıştır. Bu işlem için chunking yaklaşımı kullanılmıştır. İç içe geçen yapıları gösterebilmek amacıyla nested chunking yöntemi uygulanmış ve her kelime CHUNK-OUTER, CHUNK-INNER ve CLAUSE etiketleri ile işaretlenmiştir. Modelleme aşamasında Conditional Random Fields (CRF) yöntemi kullanılmıştır.



Şekil 1. Proje Klasör Yapısı

Şekil 1’de proje klasör yapısı gösterilmektedir. Veri dosyaları `data` klasöründe, kaynak kodlar `src` klasöründe ve çıktı dosyaları `outputs` klasöründe bulunmaktadır. Şekil 1’de görüldüğü gibi proje eğitim, test, tahmin ve değerlendirme işlemlerini ayrı

dosyalar üzerinden düzenli şekilde yürütmektedir.

2. Veri Seti ve İşaretleme

Projede veri seti CoNLL formatında hazırlanmıştır. Bu formatta her kelime ayrı bir satırda gösterilir.

Kullanılan veri formatı şu şekildedir:

ID FORM CHUNK-OUTER CHUNK-INNER CLAUSE

Bu sütunların görevleri şöyledir:

- `ID`: Kelimenin cümle içindeki sıra numarasını gösterir.
- `FORM`: Kelimenin kendisini gösterir.
- `CHUNK-OUTER`: Kelimenin içinde bulunduğu dış öbeği gösterir.
- `CHUNK-INNER`: Dış öbek içinde varsa iç öbek bilgisini gösterir.
- `CLAUSE`: Kelimenin bir cümlecik içinde yer alıp almadığını gösterir.

`CHUNK-OUTER` sütununda `B-NP`, `I-NP`, `B-VP`, `I-VP`, `B-ADVP`, `I-ADVP` ve `O` etiketleri kullanılmıştır.

Burada `NP` isim öbeğini, `VP` eylem öbeğini, `ADVP` ise zarf öbeğini göstermektedir.

`B` etiketi öbeğin başlangıcını, `I` etiketi ise öbeğin devamını ifade eder. `O` etiketi ilgili kelimenin bu sütunda bir öbeğe ait olmadığını gösterir.

`CHUNK-INNER` sütununda `B-RELCL`, `I-RELCL` ve `\_` etiketleri kullanılmıştır. Bu sütun iç içe geçen ilgi cümleciklerini göstermek için eklenmiştir. `\_` işareti ilgili kelimede iç chunk bulunmadığını belirtir.

`CLAUSE` sütununda ise `B-RELCL`, `I-RELCL`, `B-COMPCL`, `I-COMPCL` ve `O` etiketleri kullanılmıştır. Bu sütun ilgi cümlecikleri ve tümleç cümleciklerinin sınırlarını göstermek için kullanılmıştır.

Bölüm	Cümle Örneği	Token	Kullanım
Eğitim	320	2173	train.py ile model eğitimi
Test	80	543	evaluate.py ile değerlendirme
Toplam	400	2716	Tüm proje verisi

Eğitim işlemi data/train.conll dosyasıyla, değerlendirme ise data/test.conll dosyasıyla yapılmıştır.

3. Uygulama ve Kullanılan Yöntem

Bu projede yöntem olarak Conditional Random Fields (CRF) kullanılmıştır. CRF modeli, sıralı veri üzerinde etiket tahmini yapmak için uygundur. Bu nedenle kelime dizisi üzerinde çalışan chunking problemi için tercih edilmiştir.

Projede tek bir model yerine üç ayrı CRF modeli kullanılmıştır:

- Outer Chunk Modeli
- Inner Chunk Modeli
- Clause Modeli

Bu ayırım sayesinde her etiketleme sütunu kendi modelinden tahmin edilmiştir.

Outer modeli `CHUNK-OUTER` etiketlerini, Inner modeli `CHUNK-INNER` etiketlerini, Clause modeli ise `CLAUSE` etiketlerini öğrenmiştir.

`train.py` dosyası eğitim işlemini gerçekleştirir. Bu dosya `data/train.conll` dosyasını okur, cümleleri ve etiketleri alır, her kelime için özellik çıkarır ve üç ayrı CRF modelini eğitir. Eğitim sonunda modeller `outputs` klasörüne kaydedilir.

```
c:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project>python src\train.py
Eğitim verisi yükleniyor: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\data\train.conll

OUTER modeli eğitiliyor...
OUTER eğitim etiketleri: B-ADVP, B-NP, B-VP, I-ADVP, I-NP, I-VP, O
OUTER modeli kaydedildi: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\outer_model.pkl
OUTER modelinde kullanılan etiketler: B-ADVP, B-NP, B-VP, I-ADVP, I-NP, I-VP, O

INNER modeli eğitiliyor...
INNER eğitim etiketleri: B-RELCL, I-RELCL, _
INNER modeli kaydedildi: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\inner_model.pkl
INNER modelinde kullanılan etiketler: B-RELCL, I-RELCL, _

CLAUSE modeli eğitiliyor...
CLAUSE eğitim etiketleri: B-COMPCL, B-RELCL, I-COMPCL, I-RELCL, O
CLAUSE modeli kaydedildi: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\clause_model.pkl
CLAUSE modelinde kullanılan etiketler: B-COMPCL, B-RELCL, I-COMPCL, I-RELCL, O
```

Şekil 2. Model Eğitimi

Şekil 2'de `train.py` dosyasının çalıştırılması sonucu elde edilen eğitim çıktısı görülmektedir. CRF modelleri başarıyla eğitilmiş ve çıktı klasörüne kaydedilmiştir.

Şekil 2'de görüldüğü üzere OUTER, INNER ve CLAUSE modelleri ayrı ayrı oluşturulmuştur.

Model eğitimi data/train.conll dosyası üzerinde yapılmıştır. Değerlendirme aşamasında ise eğitimde kullanılmayan data/test.conll dosyası kullanılmıştır. Bu dosyada 80 test cümlesi ve 543 token bulunmaktadır. evaluate.py dosyası daha önce eğitilen OUTER, INNER ve

CLAUSE modellerini yükleyerek bu test verisi üzerinde tahmin üretmiş, ardından precision, recall, f-measure, support ve accuracy değerlerini hesaplamıştır. Confusion matrix grafikleri de yine test verisi üzerindeki gerçek etiketler ve model tahminleri karşılaştırılarak oluşturulmuştur.

```
c:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project>python src\evaluate.py
Test verisi yükleniyor: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\data\test.conll
Modeller yükleniyor...

===== CHUNK-OUTER =====
Genel model accuracy: 0.9982
Proje sonuçları başarı oranları:
Sinif      Precision  Recall  F-measure  Support
-----
B-ADVP      1.0000    0.9828    0.9913      58
B-NP         0.9940    1.0000    0.9970     166
B-VP         1.0000    1.0000    1.0000      99
I-ADVP       1.0000    1.0000    1.0000      36
I-NP         1.0000    1.0000    1.0000      80
I-VP         1.0000    1.0000    1.0000      24
O            1.0000    1.0000    1.0000      80
Macro avg   0.9991    0.9975    0.9983     543
Weighted avg 0.9982    0.9982    0.9982     543

Confusion matrix grafik olarak kaydedildi: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\outer_confusion_matrix.png
Rapor dosyası: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\outer_classification_report.txt
```

```

===== CHUNK-INNER =====
Genel model accuracy: 1.0000
Proje sonuclari basari oranlari:
Sinif      Precision  Recall  F-measure  Support
-----
B-RELCL    1.0000    1.0000    1.0000     33
I-RELCL    1.0000    1.0000    1.0000     47
-          1.0000    1.0000    1.0000    463
Macro avg  1.0000    1.0000    1.0000    543
Weighted avg 1.0000    1.0000    1.0000    543

Confusion matrix grafik olarak kaydedildi: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\inner_confusion_matrix.png
Rapor dosyasi: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\inner_classification_report.txt

```

```

===== CLAUSE =====
Genel model accuracy: 1.0000
Proje sonuclari basari oranlari:
Sinif      Precision  Recall  F-measure  Support
-----
B-COMPCL    1.0000    1.0000    1.0000     19
B-RELCL    1.0000    1.0000    1.0000     33
I-COMPCL    1.0000    1.0000    1.0000     25
I-RELCL    1.0000    1.0000    1.0000     47
O          1.0000    1.0000    1.0000    419
Macro avg  1.0000    1.0000    1.0000    543
Weighted avg 1.0000    1.0000    1.0000    543

Confusion matrix grafik olarak kaydedildi: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\clause_confusion_matrix.png
Rapor dosyasi: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\clause_classification_report.txt

```

```


===== OUTPUT DOSYALARI =====
Basari oranlari terminalde yukarida gosterildi ve outputs klasoru kaydedildi.
Metin sonuc ozeti: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\results_summary.txt
CSV metrik dosyasi: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\metrics_summary.csv
CSV accuracy dosyasi: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\accuracy_summary.csv
Birlesik degerlendirme raporu: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\evaluation_report.md

Confusion matrix grafik dosyalari:
OUTER grafik: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\outer_confusion_matrix.png
INNER grafik: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\inner_confusion_matrix.png
CLAUSE grafik: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\clause_confusion_matrix.png
Birlesik grafik: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\all_confusion_matrices.png

Genel accuracy degerleri:
OUTER: 0.9982
INNER: 1.0000
CLAUSE: 1.0000
Tahmin dosyasi: C:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_project\outputs\nested_predictions.conll

```

Şekil 3. Değerlendirme Sonuçları



Şekil 3. Değerlendirme Sonuçları
(Confusion Matrix)

Şekil 3'te `evaluate.py` tarafından üretilen performans sonuçları görülmektedir. Accuracy, precision, recall ve f-measure değerleri hesaplanmıştır.

Şekil 3'e göre model genel olarak başarılı sonuçlar üretmiştir. Ayrıca confusion matrix grafikleri de değerlendirme çıktıları arasında yer almaktadır.

Confusion matrix sonuçlarına göre OUTER modelinde yalnızca 1 hata bulunurken, INNER ve CLAUSE modelleri test verisinde hatasız sonuç üretmiştir.

`predict.py` dosyası ise kullanıcıdan yeni bir Türkçe cümle alır. Girilen cümle önce kelimelere ayrılır, daha sonra üç model kullanılarak her kelime için `CHUNK-OUTER`, `CHUNK-INNER` ve `CLAUSE` etiketi tahmin edilir. Sonuçlar terminalde tablo halinde gösterilir.

Şekil 4. Örnek Nested Chunking

```
c:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2
026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_p
roject>python src\predict.py
Türkçe bir cümle girin:
Lutfen boş olmayan bir cümle girin.

c:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2
026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_p
roject>
c:\Users\Rima Farah Eleuch\OneDrive\Desktop\SPRING SEMESTER 2
026\BLM0467_Doğal Dil İşlemeye Giriş_SB1\NLP Proje\chunking_p
roject>python src\predict.py
Türkçe bir cümle girin: Dün akşam toplantıdan erken çıkan öğrencinin makaleyi okuduğunu fark ettim.
```

ID	FORM	CHUNK-OUTER	CHUNK-INNER	CLAUSE
1	Dün	B-NP	—	0
2	akşam	B-NP	—	0
3	toplantıdan	I-NP	—	0
4	erken	I-NP	—	0
5	çıkan	I-NP	—	0
6	öğrencinin	I-NP	—	0
7	makaleyi	B-NP	—	0
8	okuduğunu	B-VP	—	0
9	fark	B-VP	—	0
10	ettim	I-VP	—	0
11	.	O	—	0

Tahmini

Şekil 4'te örnek cümle üzerinde gerçekleştirilen nested chunking tahmini görülmektedir. Sistem her kelime için `CHUNK-OUTER`, `CHUNK-INNER` ve `CLAUSE` etiketlerini üretmiştir.

Şekil 4'te örnek tahmin sonucu görülmektedir ve sistemin iç içe geçen yapıları ayrı sütunlarda gösterebildiği anlaşılmaktadır.

4. Sonuçlar

Projede 320 eğitim cümlesi ve 80 test cümlesi kullanılmıştır. Test verisi toplam 543 token içermektedir.

Değerlendirme sonuçlarına göre CHUNK-OUTER modeli %99.82 doğruluk, CHUNK-INNER ve CLAUSE modelleri ise %100 doğruluk elde etmiştir. Sonuçlar, modelin hem dış öbekleri hem de iç içe geçmiş yapıları yüksek başarıyla tahmin edebildiğini göstermektedir. Genel olarak sistem, test verisi üzerinde oldukça başarılı bir performans sergilemiştir.

5. Sonuç

Bu projede Türkçe cümlelerdeki öbek yapılarının belirlenmesi için nested chunking yöntemi kullanılmıştır. Veri seti CoNLL formatında hazırlanmış ve üç ayrı CRF modeli ile eğitim ve test işlemleri gerçekleştirilmiştir. Elde edilen sonuçlar modelin başarılı bir performans gösterdiğini ortaya koymuştur. Sonuç olarak proje, verilen gereksinimleri karşılayacak şekilde tamamlanmıştır.